ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TON
KHOA KHOA HỌC MÁY TÍNH

CÁC KĨ THUẬT HỌC SÂU VÀ ỨNG DỤNG (CS431)

BÁO CÁO ĐỒ ÁN

Hệ thống hỏi đáp từ video bài giảng

GVHD:	TS. Nguyễn Vinh Tiệp	
SV thực hiện:	Phạm Nguyên Tường	23521751
	Chướng Hồng Văn	23521769
	Tăng Hoàng Phúc	23521219

TP Hồ Chí Minh, Tháng 12 Năm 2025

Mục lục

1. Giới thiệu đề tài **3**
1.1. Bối cảnh và động lực 3
1.2. Bài toán đặt ra 3
1.3. Thách thức 3
1.4. Đóng góp chính của đề tài 3

2. Phương pháp thực hiện **4**
2.1. Tổng quan hệ thống 4
2.2. Xử lý và biểu diễn dữ liệu video 5
2.2.1. Xử lý thông tin thị giác 5
2.2.2. Xử lý thông tin âm thanh và hợp nhất đa phương thức 6
2.3. Biểu diễn và lưu trữ tri thức 6
2.3.1. Chuẩn hóa và tăng cường ngữ cảnh bằng mô hình ngôn ngữ lớn 7
2.3.2. Biểu diễn ngữ nghĩa và lưu trữ song song 7
2.4. Chiến lược truy xuất thông tin 7
2.4.1. Mở rộng và tái diễn đạt truy vấn 8
2.4.2. Truy xuất dựa trên từ khóa 8
2.4.3. Truy xuất dựa trên embedding ngữ nghĩa 8
2.4.4. Truy xuất lai kết hợp 9
2.4.5. Truy xuất tăng cường bằng reranking 9
2.5. Sinh câu trả lời 9
2.5.1. Mô hình sinh và thiết kế prompt 9
2.5.2. Sinh câu trả lời có trích dẫn 10
2.5.3. Kiểm soát chất lượng câu trả lời 10

3. Dữ liệu và độ đo đánh giá **10**
3.1. Dữ liệu sử dụng 10
3.2. Tập câu hỏi đánh giá 11
3.3. Độ đo đánh giá 11
3.3.1. Độ đo đánh giá truy xuất (Retrieval Metrics) 11
3.3.2. Độ đo đánh giá sinh câu trả lời (Generation Metrics) 12

4. Thực nghiệm **12**
4.1. Các phương pháp thực nghiệm 12
4.2. Đánh giá quá trình truy xuất thông tin 13
4.3. Đánh giá quá trình tạo sinh bằng RAGAS 14

Tóm tắt

Sự phát triển mạnh mẽ của các nền tảng giáo dục trực tuyến đã làm gia tăng đáng kể số lượng video bài giảng học thuật. Tuy nhiên, việc truy xuất và tra cứu thông tin cụ thể từ các video có thời lượng dài vẫn còn nhiều hạn chế, do người học thường phải xem thủ công hoặc tìm kiếm theo mốc thời gian một cách kém hiệu quả. Trong bối cảnh đó, bài toán *Question Answering* trên video bài giảng nổi lên như một hướng tiếp cận tiềm năng nhằm hỗ trợ người học tiếp cận kiến thức nhanh chóng và chính xác hơn.

Trong đồ án này, chúng em đề xuất một hệ thống *Question Answering* cho video bài giảng môn *Các kỹ thuật học sâu và ứng dụng (CS431)*. Hệ thống được xây dựng theo hướng *Retrieval-Augmented Generation*, kết hợp xử lý đa phương thức bao gồm hình ảnh, âm thanh và văn bản trích xuất từ video. Nội dung bài giảng được chia thành các đoạn ngữ cảnh và được biểu diễn thông qua nhiều chiến lược truy xuất khác nhau như BM25, embedding ngữ nghĩa và reranking. Cuối cùng, một mô hình ngôn ngữ lớn được sử dụng để sinh câu trả lời tự nhiên kèm theo trích dẫn nguồn từ video.

Hệ thống được đánh giá trên một bộ câu hỏi học thuật được xây dựng thủ công, sử dụng các độ đo chuyên biệt cho *Retrieval-Augmented Generation* bao gồm *Faithfulness*, *Context Precision*, *Context Recall* và *Answer Correctness*. Kết quả thực nghiệm cho thấy việc kết hợp embedding ngữ nghĩa và reranking giúp cải thiện đáng kể chất lượng truy xuất cũng như độ chính xác của câu trả lời so với các phương pháp truy xuất truyền thống.

1. Giới thiệu đề tài

1.1. Bối cảnh và động lực

Trong những năm gần đây, sự phát triển mạnh mẽ của các nền tảng giáo dục trực tuyến đã thúc đẩy việc sử dụng video bài giảng như một phương tiện học tập phổ biến trong môi trường đại học và đào tạo chuyên môn. Video bài giảng mang lại nhiều lợi ích như khả năng học tập linh hoạt, nội dung trực quan và khả năng tiếp cận rộng rãi, đặc biệt đối với các môn học mang tính học thuật và kỹ thuật cao.

Tuy nhiên, khi số lượng video ngày càng nhiều và thời lượng mỗi video ngày càng dài, người học gặp không ít khó khăn trong việc truy xuất nhanh chóng các thông tin cụ thể phục vụ cho việc ôn tập và tra cứu kiến thức. Phương pháp học tập truyền thống dựa trên việc xem toàn bộ video hoặc tìm kiếm thủ công theo mốc thời gian (timestamp) thường tốn nhiều thời gian và thiếu hiệu quả. Do đó, nhu cầu về các hệ thống hỗ trợ truy xuất tri thức một cách nhanh chóng và chính xác từ video bài giảng ngày càng trở nên cấp thiết.

1.2. Bài toán đặt ra

Trong bối cảnh đó, bài toán *Question Answering* trên video bài giảng học thuật được đặt ra nhằm hỗ trợ người học tiếp cận nội dung học tập một cách hiệu quả hơn. Mục tiêu của bài toán là xây dựng một hệ thống có khả năng tiếp nhận câu hỏi từ người dùng và tự động sinh ra câu trả lời dựa trên nội dung video bài giảng.

Đối với các video bài giảng học thuật, hệ thống không chỉ cần hiểu ngôn ngữ tự nhiên của câu hỏi mà còn phải nắm bắt được ngữ cảnh chuyên môn của môn học. Bên cạnh đó, câu trả lời sinh ra cần đảm bảo tính chính xác, đúng ngữ cảnh và đi kèm với các dẫn chứng cụ thể từ video bài giảng nhằm nâng cao độ tin cậy và khả năng kiểm chứng của kết quả.

1.3. Thách thức

Việc xây dựng một hệ thống Question Answering cho video bài giảng đặt ra nhiều thách thức đáng kể. Trước hết, dữ liệu video mang tính đa phương thức, bao gồm hình ảnh, âm thanh và văn bản, đòi hỏi hệ thống phải xử lý và tích hợp hiệu quả thông tin từ nhiều nguồn khác nhau. Đồng thời, kích thước lớn của dữ liệu video dẫn đến chi phí xử lý và lưu trữ cao.

Ngoài ra, nội dung video bài giảng thường có ngữ cảnh dài và liên tục, gây khó khăn cho việc biểu diễn và truy xuất chính xác các thông tin liên quan đến câu hỏi. Cuối cùng, hệ thống cần đạt được sự cân bằng giữa độ chính xác của câu trả lời và tốc độ truy xuất, đặc biệt trong các kịch bản sử dụng thực tế với yêu cầu phản hồi nhanh.

1.4. Đóng góp chính của đề tài

Xuất phát từ những thách thức trên, đề tài này tập trung nghiên cứu và xây dựng một hệ thống Question Answering cho video bài giảng môn *Các kỹ thuật học sâu và ứng dụng (CS431)*.

Hệ thống được thiết kế theo hướng *Retrieval-Augmented Generation*, kết hợp xử lý đa phương thức và nhiều chiến lược truy xuất thông tin khác nhau nhằm nâng cao chất lượng câu trả lời.

Các đóng góp chính của đề tài bao gồm: (i) xây dựng một pipeline hoàn chỉnh cho bài toán Question Answering trên video bài giảng học thuật, (ii) so sánh và đánh giá hiệu quả của các chiến lược truy xuất thông tin như BM25, embedding ngữ nghĩa và reranking, và (iii) đánh giá hệ thống bằng các độ đo chuyên biệt dành cho các mô hình *Retrieval-Augmented Generation*, qua đó làm rõ ưu điểm và hạn chế của từng phương pháp.

2. Phương pháp thực hiện

2.1. Tổng quan hệ thống

Hệ thống Question Answering cho video bài giảng trong đề tài này được thiết kế theo hướng *Retrieval-Augmented Generation (RAG)*, nhằm kết hợp khả năng truy xuất thông tin chính xác với năng lực sinh ngôn ngữ tự nhiên của các mô hình ngôn ngữ lớn. Mục tiêu của hệ thống là tự động trả lời các câu hỏi học thuật dựa trên nội dung video bài giảng, đồng thời cung cấp các dẫn chứng cụ thể từ nguồn dữ liệu gốc nhằm đảm bảo tính minh bạch và độ tin cậy của kết quả.

Kiến trúc tổng thể của hệ thống được chia thành hai giai đoạn chính: *offline pipeline* và *online pipeline*. Giai đoạn *offline pipeline* chịu trách nhiệm trích xuất và xây dựng cơ sở tri thức từ các video bài giảng. Do dữ liệu video mang tính đa phương thức, hệ thống tiến hành trích xuất thông tin từ nhiều nguồn khác nhau, bao gồm nội dung văn bản từ slide bài giảng, lời nói của giảng viên và các thông tin ngữ cảnh liên quan. Các dữ liệu trích xuất được xử lý, chuẩn hóa và tổ chức thành các đoạn ngữ cảnh có độ dài phù hợp, sau đó được lưu trữ trong cơ sở dữ liệu phục vụ cho quá trình truy xuất. Quy trình này được minh họa trong Hình 1.

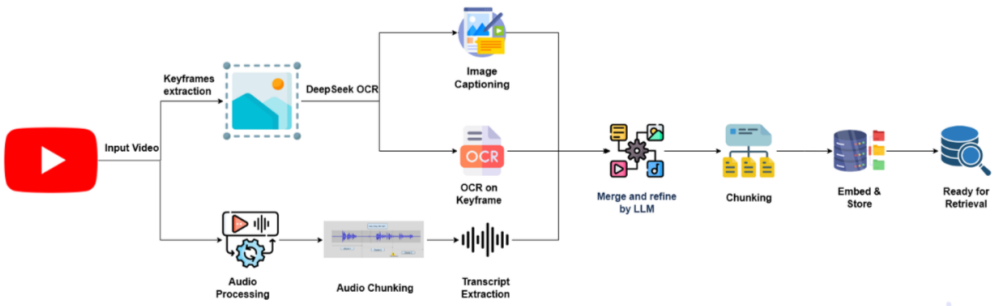

Hình 1: Quy trình trích xuất và xây dựng cơ sở tri thức đa phương thức từ video bài giảng.

Giai đoạn *online pipeline* được kích hoạt khi hệ thống tiếp nhận truy vấn từ người dùng. Tại đây, câu hỏi đầu vào được sử dụng để thực hiện truy xuất ngữ nghĩa trên cơ sở tri thức đã được xây dựng ở giai đoạn trước. Các đoạn ngữ cảnh liên quan nhất được lựa chọn và cung cấp cho mô hình sinh câu trả lời. Dựa trên các ngữ cảnh này, mô hình ngôn ngữ lớn sinh ra câu trả lời tự nhiên, đồng thời đi kèm với các trích dẫn nguồn tương ứng từ video bài giảng. Sơ đồ quy

trình của giai đoạn này được thể hiện trong Hình 2.

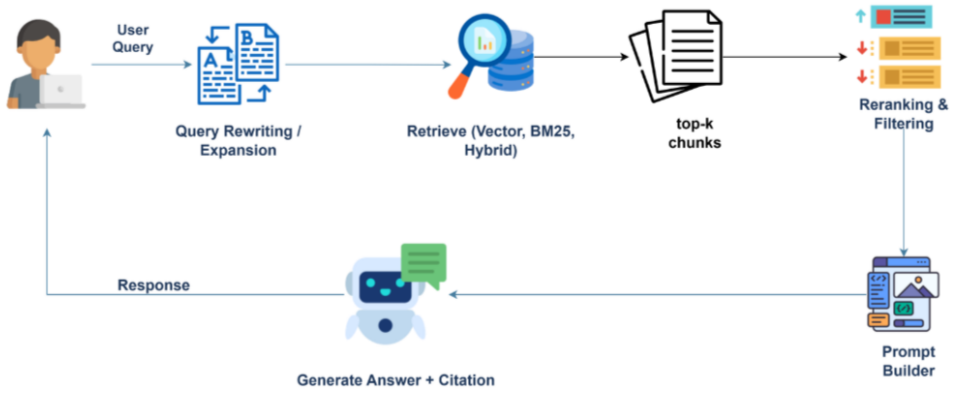

Hình 2: Sơ đồ quy trình *Retrieval-Augmented Generation* sinh câu trả lời từ cơ sở tri thức đã qua xử lý.

Cách tiếp cận hai giai đoạn này cho phép hệ thống tách biệt quá trình xử lý dữ liệu tốn kém chi phí khỏi quá trình truy vấn trực tuyến, qua đó cải thiện hiệu suất và khả năng mở rộng của hệ thống trong các kịch bản sử dụng thực tế.

2.2. Xử lý và biểu diễn dữ liệu video

Mục tiêu của giai đoạn xử lý dữ liệu là chuyển đổi video thô thành các đơn vị ngữ cảnh có cấu trúc, phục vụ cho quá trình truy xuất và sinh câu trả lời. Do video chứa thông tin dưới nhiều phương thức khác nhau, bao gồm hình ảnh hiển thị và lời nói, hệ thống tiến hành xử lý đa phương thức nhằm khai thác đầy đủ tri thức từ cả kênh thị giác và kênh âm thanh. Kết quả của giai đoạn này là một tập các đơn vị ngữ cảnh đa phương thức (*context units*), mỗi đơn vị tương ứng với một khoảng thời gian cụ thể trong video và bao gồm nội dung thị giác và nội dung lời giảng đã được trích xuất.

Quy trình xử lý được thiết kế theo hướng tách biệt cho từng phương thức dữ liệu, sau đó hợp nhất dựa trên mốc thời gian. Cụ thể, thông tin thị giác được sử dụng để xác định cấu trúc nội dung của video, trong khi thông tin âm thanh bổ sung ngữ nghĩa chi tiết từ lời giảng. Hai thành phần này được kết hợp để tạo ra biểu diễn ngữ cảnh thống nhất, làm nền tảng cho các bước truy xuất thông tin trong hệ thống.

2.2.1. Xử lý thông tin thị giác

Thông tin thị giác trong video được xử lý nhằm phát hiện và phân đoạn nội dung theo từng slide bài giảng. Trước hết, hệ thống trích xuất các khung hình từ video với tần suất cố định. Các khung hình này được sử dụng làm đầu vào cho bước phát hiện ranh giới cảnh (*shot boundary detection*), trong đó mô hình TransNetV2 được áp dụng để xác định các điểm chuyển

cảnh dựa trên sự thay đổi đột ngột về nội dung hình ảnh. Việc phát hiện cảnh giúp giới hạn phạm vi xử lý trong các đoạn video có nội dung thị giác tương đối đồng nhất.

Trong mỗi cảnh, hệ thống tiếp tục phát hiện ranh giới giữa các slide bằng cách phân tích sự thay đổi ngữ nghĩa giữa các khung hình liên tiếp. Cụ thể, mỗi khung hình được mã hóa thành vector đặc trưng thông qua mô hình CLIP với kiến trúc ViT-L/14. Độ tương đồng cosine giữa các vector đặc trưng liên tiếp được tính toán để ước lượng mức độ thay đổi nội dung. Một cơ chế ngưỡng động kết hợp với làm mượt tín hiệu được sử dụng để phát hiện các điểm thay đổi slide một cách ổn định, đồng thời hạn chế nhiễu do chuyển động nhỏ hoặc thay đổi ánh sáng.

Sau khi xác định các đoạn slide, hệ thống thực hiện lựa chọn keyframe đại diện cho từng đoạn. Quá trình này được triển khai theo một chiến lược tham lam, kết hợp giữa chất lượng hình ảnh và tính đa dạng nội dung. Chất lượng hình ảnh được đánh giá dựa trên độ sắc nét (variance của Laplacian) và entropy của ảnh, trong khi tính đa dạng được đảm bảo bằng cách hạn chế sự tương đồng ngữ nghĩa giữa các keyframe đã chọn thông qua đặc trưng CLIP. Các keyframe được chọn đóng vai trò là đại diện thị giác cho từng đoạn slide.

Văn bản hiển thị trên slide được trích xuất từ các keyframe bằng mô hình nhận dạng ký tự quang học DeepSeek-OCR. Kết quả OCR được gán cho từng đoạn slide tương ứng và được xem là thành phần thông tin thị giác trong các đơn vị ngữ cảnh.

2.2.2. Xử lý thông tin âm thanh và hợp nhất đa phương thức

Song song với xử lý thị giác, hệ thống tiến hành xử lý thông tin âm thanh nhằm trích xuất nội dung lời giảng. Âm thanh được tách riêng khỏi video và trải qua các bước tiền xử lý, bao gồm lọc nhiễu tần số thấp, giảm nhiễu phổ và chuẩn hóa cường độ tín hiệu, nhằm cải thiện chất lượng đầu vào cho mô hình nhận dạng giọng nói.

Do video có thời lượng dài, tín hiệu âm thanh được chia thành các đoạn ngắn với độ dài cố định để đảm bảo khả năng xử lý ổn định. Các đoạn âm thanh sau đó được chuyển đổi thành văn bản bằng mô hình nhận dạng giọng nói Whisper, đồng thời giữ lại thông tin mốc thời gian cho từng đoạn transcript. Kết quả của bước này là một tập các đoạn lời giảng được gắn với khoảng thời gian xuất hiện trong video.

Cuối cùng, thông tin thị giác và thông tin âm thanh được hợp nhất để tạo thành các đơn vị ngữ cảnh đa phương thức. Mỗi đoạn slide được xem là một đơn vị cấu trúc chính, trong đó các đoạn transcript có khoảng thời gian chồng lấp sẽ được gộp vào cùng đơn vị. Văn bản thị giác và văn bản âm thanh được kết hợp với các nhãn phân biệt rõ ràng, tạo thành biểu diễn ngữ cảnh hoàn chỉnh kèm theo mốc thời gian bắt đầu và kết thúc. Các đơn vị ngữ cảnh này được sử dụng làm đầu vào trực tiếp cho giai đoạn truy xuất và sinh câu trả lời của hệ thống.

2.3. Biểu diễn và lưu trữ tri thức

Sau giai đoạn xử lý và hợp nhất đa phương thức, hệ thống thu được một tập các đơn vị ngữ cảnh đa phương thức, mỗi đơn vị tương ứng với một khoảng thời gian xác định trong video và bao gồm nội dung thị giác từ slide bài giảng cùng nội dung lời giảng tương ứng. Để phục vụ cho các chiến lược truy xuất thông tin khác nhau, các đơn vị ngữ cảnh này được chuẩn hóa, biểu diễn và lưu trữ theo nhiều dạng, nhằm hỗ trợ cả truy xuất dựa trên từ khóa và truy xuất dựa

trên ngữ nghĩa.

2.3.1. Chuẩn hóa và tăng cường ngữ cảnh bằng mô hình ngôn ngữ lớn

Văn bản trích xuất trực tiếp từ slide và lời giảng thường mang tính không đồng nhất, chứa nhiều ký hiệu, câu nói rời rạc hoặc phụ thuộc mạnh vào ngữ cảnh trình bày. Những đặc điểm này có thể làm giảm hiệu quả của các phương pháp truy xuất, đặc biệt là truy xuất dựa trên từ khóa. Do đó, hệ thống áp dụng một bước chuẩn hóa và tăng cường ngữ cảnh bằng mô hình ngôn ngữ lớn.

Cụ thể, mỗi đơn vị ngữ cảnh được cung cấp cho mô hình ngôn ngữ lớn Gemini để sinh ra một phiên bản văn bản đã được viết lại với cấu trúc rõ ràng, mạch lạc và giàu ngữ nghĩa hơn, đồng thời vẫn bảo toàn nội dung thông tin gốc. Phiên bản văn bản này giúp làm nổi bật các khái niệm chính và thuật ngữ học thuật quan trọng, qua đó cải thiện khả năng truy xuất của hệ thống. Văn bản gốc và văn bản đã được chuẩn hóa được lưu trữ song song để phục vụ cho các chiến lược truy xuất khác nhau.

2.3.2. Biểu diễn ngữ nghĩa và lưu trữ song song

Đối với truy xuất dựa trên ngữ nghĩa, mỗi đơn vị ngữ cảnh được ánh xạ vào không gian vector liên tục thông qua các mô hình embedding ngữ nghĩa tiếng Việt. Trong đề tài này, hai mô hình embedding được sử dụng và so sánh là *hiieu/halong_ embedding* và *dangvantuan/vietnamese-embedding*. Các mô hình này được lựa chọn nhằm đánh giá khả năng biểu diễn ngữ nghĩa của các embedding tiếng Việt trong bối cảnh nội dung học thuật.

Các vector embedding thu được được lưu trữ trong cơ sở dữ liệu vector và được sử dụng để tính toán độ tương đồng cosine giữa câu hỏi và các đơn vị ngữ cảnh. Song song với đó, văn bản của các đơn vị ngữ cảnh đã được chuẩn hóa cũng được lập chỉ mục bằng phương pháp truy xuất dựa trên từ khóa BM25. Việc lưu trữ song song hai dạng biểu diễn này cho phép hệ thống tận dụng ưu điểm của cả hai hướng tiếp cận: khả năng nắm bắt ngữ nghĩa của embedding và tính ổn định, hiệu quả của truy xuất dựa trên từ khóa.

Ngoài nội dung văn bản và biểu diễn vector, mỗi đơn vị ngữ cảnh còn được gắn kèm các siêu dữ liệu quan trọng, bao gồm mốc thời gian bắt đầu và kết thúc trong video, cũng như các thông tin định danh liên quan đến đoạn nội dung tương ứng. Các siêu dữ liệu này cho phép hệ thống liên kết trực tiếp kết quả truy xuất với nguồn dữ liệu gốc, hỗ trợ việc sinh câu trả lời có trích dẫn và nâng cao tính minh bạch của hệ thống.

Cách tổ chức tri thức theo các đơn vị ngữ cảnh độc lập, kết hợp chuẩn hóa bằng mô hình ngôn ngữ lớn và lưu trữ song song dưới dạng văn bản và vector, tạo nền tảng vững chắc cho các chiến lược truy xuất thông tin và reranking được trình bày trong các phần tiếp theo.

2.4. Chiến lược truy xuất thông tin

Dựa trên các đơn vị ngữ cảnh đã được biểu diễn và lưu trữ, hệ thống áp dụng nhiều chiến lược truy xuất thông tin khác nhau nhằm đánh giá ảnh hưởng của từng phương pháp đến chất lượng truy xuất và câu trả lời cuối cùng. Các chiến lược này bao gồm truy xuất dựa trên từ

khóa, truy xuất dựa trên embedding ngữ nghĩa, truy xuất lai kết hợp, cũng như truy xuất tăng cường bằng reranking. Trước khi thực hiện truy xuất, hệ thống áp dụng một bước xử lý truy vấn nhằm cải thiện khả năng khớp giữa câu hỏi của người dùng và cơ sở tri thức.

2.4.1. Mở rộng và tái diễn đạt truy vấn

Trong thực tế, truy vấn do người dùng cung cấp thường ngắn gọn, thiếu ngữ cảnh hoặc sử dụng cách diễn đạt không trùng khớp với nội dung trong cơ sở tri thức. Điều này có thể làm giảm hiệu quả của các phương pháp truy xuất, đặc biệt là các phương pháp dựa trên từ khóa. Do đó, hệ thống áp dụng một bước mở rộng và tái diễn đạt truy vấn trước khi tiến hành truy xuất thông tin.

Cụ thể, truy vấn ban đầu được cung cấp cho mô hình ngôn ngữ lớn Gemini để sinh ra một phiên bản truy vấn đã được chuẩn hóa và mở rộng. Quá trình này bao gồm việc làm rõ ý định của người dùng, bổ sung các thuật ngữ học thuật liên quan và tái diễn đạt truy vấn theo cách phù hợp hơn với nội dung bài giảng. Phiên bản truy vấn sau khi được xử lý được sử dụng song song với truy vấn gốc trong các bước truy xuất tiếp theo.

2.4.2. Truy xuất dựa trên từ khóa

Chiến lược truy xuất cơ sở được sử dụng trong đề tài là phương pháp BM25, một mô hình truy xuất dựa trên từ khóa phổ biến trong lĩnh vực Information Retrieval. BM25 đánh giá mức độ liên quan giữa truy vấn và các đơn vị ngữ cảnh dựa trên tần suất xuất hiện của từ khóa, độ dài văn bản và các hệ số điều chỉnh.

Trong cấu hình này, cả truy vấn gốc và truy vấn đã được tái diễn đạt đều được sử dụng để tìm kiếm trên chỉ mục văn bản. Phương pháp BM25 cho thấy hiệu quả trong các trường hợp truy vấn có sự trùng khớp rõ ràng về mặt từ vựng với nội dung bài giảng, tuy nhiên vẫn gặp hạn chế đối với các câu hỏi mang tính diễn giải hoặc sử dụng từ đồng nghĩa.

2.4.3. Truy xuất dựa trên embedding ngữ nghĩa

Để khắc phục các hạn chế của truy xuất dựa trên từ khóa, hệ thống áp dụng truy xuất dựa trên embedding ngữ nghĩa. Trong cấu hình này, truy vấn và các đơn vị ngữ cảnh được ánh xạ vào cùng một không gian vector liên tục thông qua các mô hình embedding tiếng Việt. Hai mô hình embedding được sử dụng và so sánh trong đề tài là *hiieu/halong_embedding* và *dangvantuan/vietnamese-embedding*.

Độ tương đồng giữa truy vấn và các đơn vị ngữ cảnh được tính toán bằng độ đo cosine, từ đó lựa chọn ra các ngữ cảnh có mức độ liên quan cao nhất. Việc sử dụng truy vấn đã được tái diễn đạt giúp cải thiện khả năng biểu diễn ý định của người dùng trong không gian embedding, đặc biệt đối với các câu hỏi phức tạp hoặc mang tính suy luận.

2.4.4. Truy xuất lai kết hợp

Bên cạnh các phương pháp truy xuất đơn lẻ, hệ thống triển khai chiến lược truy xuất lai kết hợp giữa BM25 và embedding ngữ nghĩa. Trong cấu hình này, các ngữ cảnh được truy xuất độc lập từ hai phương pháp sẽ được hợp nhất nhằm tận dụng ưu điểm của cả truy xuất dựa trên từ khóa và truy xuất dựa trên ngữ nghĩa.

Chiến lược truy xuất lai cho phép hệ thống tăng độ bao phủ của các ngữ cảnh liên quan, đồng thời giảm nguy cơ bỏ sót thông tin trong các trường hợp truy vấn có cách diễn đạt khác biệt so với nội dung bài giảng. Đây là một bước trung gian quan trọng trước khi áp dụng các kỹ thuật tinh chỉnh nâng cao.

2.4.5. Truy xuất tăng cường bằng reranking

Để tiếp tục nâng cao chất lượng truy xuất, hệ thống áp dụng một bước reranking trên tập các ngữ cảnh đã được truy xuất. Cụ thể, mô hình *BAAI/bge-reranker-base* được sử dụng để đánh giá lại mức độ liên quan giữa truy vấn và từng đơn vị ngữ cảnh thông qua cơ chế so khớp cặp câu hỏi–ngữ cảnh.

Các ngữ cảnh sau khi được reranking sẽ được sắp xếp lại và lựa chọn để cung cấp cho mô hình sinh câu trả lời. Bước reranking giúp giảm nhiễu, ưu tiên các ngữ cảnh có giá trị thông tin cao và đóng vai trò quan trọng trong việc nâng cao chất lượng câu trả lời cuối cùng của hệ thống.

2.5. Sinh câu trả lời

Sau khi hoàn tất quá trình truy xuất, hệ thống tiến hành sinh câu trả lời dựa trên các đơn vị ngữ cảnh đã được lựa chọn. Giai đoạn này đóng vai trò quan trọng trong việc chuyển đổi các thông tin truy xuất được thành câu trả lời tự nhiên, dễ hiểu và phù hợp với ngữ cảnh học thuật của câu hỏi đầu vào.

2.5.1. Mô hình sinh và thiết kế prompt

Hệ thống sử dụng mô hình ngôn ngữ lớn Gemini để sinh câu trả lời. Mô hình được cung cấp truy vấn của người dùng cùng với tập các đơn vị ngữ cảnh đã được truy xuất và sắp xếp theo mức độ liên quan. Để đảm bảo câu trả lời sinh ra bám sát nội dung bài giảng và hạn chế việc sinh thông tin không có căn cứ, hệ thống áp dụng một thiết kế prompt có ràng buộc rõ ràng.

Cụ thể, prompt yêu cầu mô hình chỉ sử dụng thông tin xuất hiện trong các ngữ cảnh được cung cấp, không bổ sung kiến thức bên ngoài và trình bày câu trả lời theo phong cách học thuật. Ngoài ra, prompt cũng hướng dẫn mô hình làm rõ các khái niệm chính, thuật ngữ quan trọng và mối quan hệ giữa các ý, nhằm nâng cao tính mạch lạc và dễ hiểu của câu trả lời.

2.5.2. Sinh câu trả lời có trích dẫn

Một yêu cầu quan trọng của hệ thống là khả năng cung cấp các dẫn chứng cụ thể từ video bài giảng cho mỗi câu trả lời. Do đó, mỗi đơn vị ngữ cảnh được gắn kèm với các siêu dữ liệu về mốc thời gian và định danh nội dung. Trong quá trình sinh câu trả lời, mô hình được yêu cầu liên kết các phần nội dung trong câu trả lời với các đơn vị ngữ cảnh tương ứng.

Kết quả đầu ra của hệ thống bao gồm câu trả lời bằng ngôn ngữ tự nhiên và danh sách các trích dẫn nguồn, trong đó mỗi trích dẫn tương ứng với một hoặc nhiều mốc thời gian trong video. Cách tiếp cận này giúp người dùng dễ dàng kiểm chứng thông tin và quay lại đoạn video liên quan để xem chi tiết.

2.5.3. Kiểm soát chất lượng câu trả lời

Để nâng cao độ tin cậy của câu trả lời, hệ thống áp dụng các cơ chế kiểm soát chất lượng trong quá trình sinh. Trước hết, số lượng và độ dài của các ngữ cảnh được giới hạn nhằm tránh đưa vào các thông tin không liên quan. Bên cạnh đó, việc sắp xếp các ngữ cảnh theo mức độ liên quan giúp mô hình ưu tiên các thông tin quan trọng nhất khi sinh câu trả lời.

Ngoài ra, hệ thống có thể áp dụng các ràng buộc hậu xử lý nhằm phát hiện và loại bỏ các câu trả lời thiếu căn cứ hoặc không bám sát ngữ cảnh truy xuất. Những cơ chế này góp phần giảm thiểu hiện tượng sinh thông tin sai lệch và đảm bảo rằng câu trả lời phản ánh trung thực nội dung bài giảng.

3. Dữ liệu và độ đo đánh giá

3.1. Dữ liệu sử dụng

Dữ liệu đầu vào của hệ thống là tập hợp các video bài giảng thuộc môn học *CS431 – Các kỹ thuật học sâu và ứng dụng*. Các video này ghi lại toàn bộ nội dung giảng dạy của môn học, bao gồm cả hình ảnh slide trình chiếu và phần thuyết giảng bằng lời của giảng viên.

Hệ thống kiến thức trong các video bài giảng trải dài từ các thuật toán học máy cơ bản như *Linear Regression* và *Logistic Regression* đến các mô hình học sâu chuyên sâu như *Neural Networks* và *Convolutional Neural Networks (CNN)*. Nội dung môn học tập trung vào các ứng dụng tiêu biểu của học sâu trong các lĩnh vực như Thị giác máy tính và Xử lý ngôn ngữ tự nhiên, qua đó tạo ra một tập dữ liệu mang tính học thuật cao và có độ đa dạng về chủ đề.

Các video bài giảng có độ phân giải cao, đảm bảo chất lượng hình ảnh slide đủ rõ ràng cho quá trình trích xuất thông tin thị giác, đồng thời bao gồm đầy đủ phần giọng nói của giảng viên TS. Nguyễn Vinh Tiệp. Đặc điểm này cho phép hệ thống khai thác hiệu quả cả hai nguồn thông tin chính là nội dung hiển thị và nội dung lời giảng, phục vụ cho việc xây dựng các đơn vị ngữ cảnh đa phương thức.

Từ tập video này, hệ thống tiến hành trích xuất và xây dựng cơ sở tri thức thông qua quy trình xử lý đã được trình bày ở các phần trước. Các đơn vị ngữ cảnh thu được đóng vai trò là nền tảng cho toàn bộ quá trình truy xuất thông tin và sinh câu trả lời trong hệ thống.

3.2. Tập câu hỏi đánh giá

Để đánh giá hiệu quả của hệ thống, một tập câu hỏi học thuật được xây dựng thủ công dựa trên nội dung các bài giảng. Các câu hỏi được thiết kế nhằm kiểm tra khả năng truy xuất và tổng hợp thông tin của hệ thống ở nhiều mức độ khác nhau, bao gồm câu hỏi kiểm tra kiến thức cơ bản, câu hỏi yêu cầu giải thích khái niệm và câu hỏi mang tính suy luận.

Mỗi câu hỏi được gán kèm một câu trả lời chuẩn (*ground truth*) do con người xây dựng, phản ánh nội dung chính xác cần được truy xuất từ video bài giảng. Ngoài ra, các đoạn ngữ cảnh liên quan trong video cũng được xác định nhằm phục vụ cho việc đánh giá chất lượng truy xuất.

	A	B
1	**Question**	**Reference**
2	Tại sao trong bài toán phân lớp ta không sử dụng hàm lỗi MSE mà lại dùng Cross-Entropy ?	mse không phù hợp cho phân lớp vì nó tạo ra gradient rất nhỏ khi mô hình dự đoán sai, dẫn đến học chậm và dễ rơi vào điểm kém tối ưu, trong khi cross entropy tạo gradient lớn khi dự đoán sai và gradient nhỏ khi dự đoán đúng, giúp mô hình học nhanh, ổn định và tương thích tự nhiên với softmax vì nó đo trực tiếp độ lệch giữa hai phân phối xác suất nên tối ưu hóa dễ dàng và cho ranh giới quyết định tốt hơn.
3	Vấn đề nghiêm trọng nào phát sinh khi áp dụng mạng Neural Network truyền thống (Fully Connected) cho bài toán phân loại ảnh phức tạp?	khi áp dụng mạng neural network truyền thống (fully connected) cho phân loại ảnh phức tạp, ta gặp các vấn đề nghiêm trọng: số lượng tham số tăng cực lớn dẫn đến mô hình rất dễ quá khớp và khó huấn luyện; mạng không tận dụng được cấu trúc không gian của ảnh vì coi toàn bộ ảnh như một vector phẳng, làm mất thông tin cục bộ quan trọng; mô hình không có tính bất biến theo dịch chuyển nên chỉ cần đối tượng di chuyển vị trí thì đặc trưng phải được học lại, khiến việc học kém hiệu quả và yêu cầu dữ liệu lớn
4	Thách thức lớn nhất khi huấn luyện một mạng nơ-ron có số lượng tham số khổng lồ là gì?	Thách thức lớn nhất là cân bằng dung lượng mô hình và khả năng khái quát. Mô hình lớn dễ học các nhiễu và chi tiết tạp trên dữ liệu huấn luyện, dẫn đến overfitting nếu không có lượng dữ liệu và regularization phù hợp. Đồng thời, chi phí tính toán và bộ nhớ để lưu tham số, tính forward/backward và cập nhật gradients rất cao, đòi hỏi phần cứng mạnh, chiến lược phân tán và tối ưu đặc biệt. Ngoài ra, mặt phẳng tối ưu có thể rất phức tạp, khiến việc tối ưu trở nên khó khăn; các vấn đề như vanishing hoặc exploding gradient, cần khởi tạo, tối ưu, điều chỉnh tỷ lệ học và kỹ thuật như gradient clipping, batch normalization, hay optimizer đặc biệt để đảm bảo hội tụ
5	Trong mạng CNN, các trọng số của bộ lọc (filter) được xác định như thế nào và chức năng chính của chúng là gì?	Trọng số của bộ lọc là các tham số học được thông qua quá trình huấn luyện bằng cách tối ưu hàm mất mát và lan truyền ngược gradient. Mỗi bộ lọc có kích thước nhỏ so với ảnh và được áp dụng trên toàn ảnh theo cửa sổ trượt để dò tìm mẫu cục bộ. Chức năng chính của các trọng số này là phát hiện các đặc trưng cục bộ, từ các cạnh và góc ở các tầng nông đến các họa tiết và cấu trúc phức tạp hơn ở các tầng sâu.

Hình 3: Minh họa cho tập câu hỏi đánh giá

3.3. Độ đo đánh giá

Để đánh giá hiệu quả của hệ thống một cách toàn diện, đề tài sử dụng hai nhóm độ đo chính, tương ứng với hai giai đoạn quan trọng trong pipeline: (i) đánh giá chất lượng truy xuất ngữ cảnh và (ii) đánh giá chất lượng câu trả lời sinh ra. Cách tiếp cận này cho phép phân tích riêng biệt ảnh hưởng của từng thành phần trong hệ thống Retrieval-Augmented Generation.

3.3.1. Độ đo đánh giá truy xuất (Retrieval Metrics)

Các độ đo truy xuất được sử dụng nhằm đánh giá khả năng của hệ thống trong việc tìm kiếm và xếp hạng các đơn vị ngữ cảnh liên quan đến câu hỏi đầu vào. Những độ đo này phản ánh trực tiếp hiệu quả của các chiến lược truy xuất như BM25, embedding ngữ nghĩa và truy xuất lai.

- **Mean Reciprocal Rank (MRR)**: Độ đo này đánh giá vị trí xuất hiện của đơn vị ngữ cảnh đúng đầu tiên trong danh sách kết quả truy xuất. Với mỗi truy vấn, nghịch đảo thứ hạng của kết quả đúng đầu tiên được tính toán, và MRR là giá trị trung bình của các nghịch đảo này trên toàn bộ tập truy vấn. Giá trị MRR càng cao (tiệm cận 1) cho thấy hệ thống có xu hướng đưa các ngữ cảnh đúng lên các vị trí đầu danh sách, điều này đặc biệt quan trọng trong các hệ thống Question Answering chỉ sử dụng một số lượng nhỏ ngữ cảnh đầu vào cho bước sinh câu trả lời.
- **Hit Rate @ k (Hit@k)**: Độ đo Hit@k đánh giá tỷ lệ truy vấn mà trong đó ít nhất một

đơn vị ngữ cảnh đúng (ground truth context) xuất hiện trong top-k kết quả truy xuất đầu tiên. Trong đề tài này, các giá trị $k \in \{1, 3, 5\}$ được sử dụng nhằm phản ánh hiệu quả truy xuất ở các mức độ khác nhau. Hit@k đặc biệt hữu ích trong việc đánh giá khả năng bao phủ của hệ thống khi số lượng ngữ cảnh được cung cấp cho mô hình sinh câu trả lời bị giới hạn.

3.3.2. Độ đo đánh giá sinh câu trả lời (Generation Metrics)

Để đánh giá chất lượng câu trả lời sinh ra bởi mô hình ngôn ngữ lớn, đề tài sử dụng bộ công cụ RAGAS, một framework được thiết kế chuyên biệt cho việc đánh giá các hệ thống Retrieval-Augmented Generation. RAGAS áp dụng cơ chế *LLM-as-a-judge*, trong đó mô hình ngôn ngữ lớn được sử dụng như một bộ đánh giá để so sánh câu trả lời sinh ra với ngữ cảnh truy xuất và câu trả lời chuẩn.

Các độ đo được sử dụng bao gồm:

- **Faithfulness (Độ trung thực)**: Độ đo này đánh giá mức độ mà câu trả lời sinh ra tuân thủ chặt chẽ các thông tin có trong tập ngữ cảnh được truy xuất. Faithfulness giúp phát hiện và hạn chế hiện tượng ảo giác (hallucination), trong đó mô hình sinh ra các thông tin không xuất hiện trong dữ liệu đầu vào. Giá trị cao của Faithfulness cho thấy câu trả lời được sinh ra có cơ sở rõ ràng từ các ngữ cảnh được cung cấp.
- **Context Precision (Độ chính xác ngữ cảnh)**: Độ đo này phản ánh tỷ lệ các đơn vị ngữ cảnh thực sự liên quan đến câu hỏi trong tổng số các ngữ cảnh được truy xuất. Context Precision cao cho thấy hệ thống truy xuất có khả năng lọc nhiễu tốt, hạn chế việc đưa vào các đoạn văn bản không cần thiết cho quá trình sinh câu trả lời.
- **Context Recall (Độ phủ ngữ cảnh)**: Độ đo Context Recall đánh giá mức độ mà các ngữ cảnh được truy xuất bao phủ đầy đủ thông tin cần thiết để trả lời câu hỏi, dựa trên so sánh với câu trả lời chuẩn (ground truth). Chỉ số này phản ánh khả năng của hệ thống trong việc không bỏ sót các thông tin quan trọng.
- **Answer Correctness (Độ chính xác câu trả lời)**: Độ đo này đánh giá mức độ tương đồng về mặt ngữ nghĩa và tính đúng đắn về mặt nội dung giữa câu trả lời sinh ra và câu trả lời chuẩn. Answer Correctness tập trung vào ý nghĩa và tính chính xác của câu trả lời, thay vì yêu cầu sự trùng khớp tuyệt đối về mặt từ vựng.

Việc kết hợp các độ đo truy xuất và độ đo sinh câu trả lời cho phép đánh giá toàn diện hiệu quả của hệ thống, đồng thời làm rõ mối quan hệ giữa chất lượng truy xuất ngữ cảnh và chất lượng câu trả lời cuối cùng trong bài toán Question Answering trên video bài giảng.

4. Thực nghiệm

4.1. Các phương pháp thực nghiệm

Để đánh giá một cách toàn diện ảnh hưởng của các chiến lược truy xuất, đề tài tiến hành so sánh nhiều cấu hình thực nghiệm khác nhau. Các cấu hình này được xây dựng dựa trên sự kết

hợp giữa các phương pháp truy xuất ngữ cảnh và mô hình sinh câu trả lời. Cụ thể, các phương pháp được sử dụng bao gồm:

- **BM25**: Phương pháp truy xuất dựa trên từ khóa, được sử dụng làm mô hình cơ sở (baseline).
- **dangvantuan/vietnamese-embedding**: Phương pháp truy xuất dựa hoàn toàn trên embedding ngữ nghĩa tiếng Việt, không sử dụng truy xuất từ khóa.
- **hiieu/halong_embedding**: Phương pháp truy xuất dense embedding được thiết kế nhằm biểu diễn tốt hơn các nội dung học thuật tiếng Việt.
- **BM25 + hiieu/halong_embedding**: Chiến lược truy xuất lai (hybrid search), kết hợp ưu điểm của truy xuất từ khóa và truy xuất ngữ nghĩa để tăng độ bao phủ của ngữ cảnh.
- **hiieu/halong_embedding + BAAI/bge-reranker-base**: Chiến lược truy xuất tăng cường, trong đó các ngữ cảnh truy xuất bằng embedding được tinh chỉnh lại thứ hạng thông qua mô hình reranking.

Trong giai đoạn sinh câu trả lời, tất cả các cấu hình đều sử dụng cùng một mô hình ngôn ngữ lớn Gemini nhằm đảm bảo tính công bằng khi so sánh. Do đó, sự khác biệt về kết quả phản ánh trực tiếp hiệu quả của các chiến lược truy xuất ngữ cảnh.

4.2. Đánh giá quá trình truy xuất thông tin

Bảng **??** trình bày kết quả đánh giá hiệu suất truy xuất thông tin của các cấu hình thực nghiệm thông qua các độ đo MRR và Hit@k.

Kỹ thuật	**MRR**	**Hit@1**	**Hit@3**	**Hit@5**
hiieu/halong_embedding + BAAI/bge-reranker-base	**0.970**	**0.94**	**1.00**	**1.00**
hiieu/halong_embedding	0.958	0.94	0.96	0.98
BM25 + hiieu/halong_embedding	0.915	0.84	0.98	**1.00**
BM25	0.844	0.74	0.96	0.98
dangvantuan/vietnamese-embedding	0.581	0.42	0.68	0.80

Bảng 1: Kết quả đánh giá hiệu suất truy xuất thông tin

Trong các thực nghiệm ban đầu, BM25 được lựa chọn làm mô hình cơ sở. Kết quả cho thấy BM25 đạt hiệu suất tương đối tốt ở các chỉ số Hit@3 và Hit@5, cho thấy phương pháp này có khả năng tìm ra các ngữ cảnh liên quan trong danh sách kết quả trả về. Tuy nhiên, chỉ số Hit@1 chỉ đạt 0.74, phản ánh hạn chế của BM25 trong việc xếp hạng chính xác ngữ cảnh quan trọng nhất ở vị trí đầu tiên. Điều này cho thấy truy xuất dựa trên từ khóa gặp khó khăn khi phải phân biệt mức độ liên quan tinh tế giữa các ngữ cảnh học thuật có nội dung gần nhau.

Khi chuyển sang các phương pháp truy xuất dựa trên embedding ngữ nghĩa, hiệu suất truy xuất được cải thiện đáng kể. Đặc biệt, mô hình *hiieu/halong_embedding* cho kết quả vượt trội so với *dangvantuan/vietnamese-embedding*, chứng tỏ khả năng biểu diễn ngữ nghĩa phù hợp

hơn với nội dung bài giảng học thuật. Chiến lược truy xuất lai (BM25 + embedding) giúp tăng độ bao phủ của ngữ cảnh, thể hiện qua chỉ số Hit@5 đạt giá trị tuyệt đối.

Hiệu quả cao nhất đạt được khi tích hợp thêm bước reranking. Cấu hình *hiieu/halong_ embedding + BAAI/bge-reranker-base* đạt chỉ số MRR cao nhất (0.970) và Hit@1 lên tới 0.94, đồng thời đạt độ chính xác tuyệt đối ở Hit@3 và Hit@5. Điều này cho thấy reranker đóng vai trò then chốt trong việc tinh chỉnh thứ hạng và lựa chọn chính xác các ngữ cảnh quan trọng nhất.

4.3. Đánh giá quá trình tạo sinh bằng RAGAS

Bảng 2 trình bày kết quả đánh giá chất lượng câu trả lời sinh ra bằng bộ tiêu chí RAGAS, bao gồm Faithfulness, Context Precision, Context Recall và Answer Correctness.

Phương pháp	**Faithfulness**	**Context Precision**	**Context Recall**	**Answer Correctness**
BM25 + Gemini	0.9170	0.8261	0.8167	0.6059
dangvantuan/vietnamese-embedding + Gemini	0.7631	0.6800	0.6880	0.5590
hiieu/halong_embedding + Gemini	0.9181	**0.94**	0.8894	0.6351
hiieu/halong_embedding + BM25 + Gemini	0.9437	0.8776	**0.9192**	0.6353
hiieu/halong_embedding + BAAI/bge-reranker-base + Gemini	**0.9497**	0.8800	0.8967	**0.6391**

Bảng 2: Kết quả đánh giá mô hình RAG sử dụng bộ tiêu chí RAGAS

Kết quả cho thấy chất lượng câu trả lời sinh ra có mối liên hệ chặt chẽ với chất lượng truy xuất ngữ cảnh. Các cấu hình sử dụng embedding ngữ nghĩa cho giá trị Context Precision và Answer Correctness cao hơn so với BM25 đơn thuần, phản ánh khả năng cung cấp các ngữ cảnh phù hợp hơn cho mô hình sinh câu trả lời.

Chiến lược truy xuất lai giúp cải thiện đáng kể Context Recall, cho thấy khả năng bao phủ đầy đủ thông tin cần thiết để trả lời câu hỏi. Đặc biệt, cấu hình kết hợp embedding và reranking đạt kết quả tốt nhất ở hai độ đo quan trọng nhất là Faithfulness (0.9497) và Answer Correctness (0.6391). Điều này chứng minh rằng việc tinh chỉnh thứ hạng ngữ cảnh không chỉ cải thiện truy xuất mà còn trực tiếp nâng cao độ chính xác và độ tin cậy của câu trả lời cuối cùng.